



Universidade Federal Fluminense



TÓPICOS ESP. SIST. INFORMAÇÃO



Prof.^aLeila Weitzel



2. Fundamentos de Redes Neurais

Neurônios Artificiais

- As RNA existem desde a década de 1940, quando foram propostas pela primeira vez por MCCULLOCH; PITTS (1943) inspirado em um modelo neurônio biológico.
- A rede consistia em um conjunto de entradas, cada uma das quais era multiplicada por um peso e somada (era combinação linear das entradas com os pesos associados). Se a soma excedeu um limite limiar, a rede gera saída igual a 1 (um), e 0 (zero) caso contrário.


Neurônios Artificiais

- Inspiração na Biologia, nos neurônios, processamento químico do cérebro



Neurônios Artificiais

- E entrada de 1..n e saída Y



Neurônios Artificiais

- Modelagem de um neurônio Biológico :
- a polarização E_{si} da membrana pós-sináptica é proporcional a frequência média w_i dos pulsos que chegam à sinapse, através de uma constante de proporcionalidade k_i cujo sinal e magnitude dependem da característica da sinapse.
- Assim, no axônio, a polarização resultante será de:

$$E = a_1 E_{s1} + a_2 E_{s2} \rightarrow a_1 k_1 w_1 + a_2 k_2 w_2 \rightarrow b_1 w_1 + b_2 w_2$$

- $b_1 = a_1 k_1$ e $b_2 = a_2 k_2$ incorporam a atenuação devido a difusão passiva e o ganho da sinapse

Neurônios Artificiais

- **Modelagem de um neurônio Biológico :**
- Tal que, para qualquer par de valores das excitações sinápticas w_1, w_2 , tem-se que:
- Diz-se que é uma combinação linear das entradas com pesos associados.


$$b_1w_1 + b_2w_2 > E^* + \varepsilon \rightarrow f(E) = f(b_1w_1 + b_2w_2) \cong \mathbf{1000 \text{ pulsos/seg}}$$

$$b_1w_1 + b_2w_2 < E^* - \varepsilon \rightarrow f(E) = f(b_1w_1 + b_2w_2) \cong \mathbf{0 \text{ pulsos/seg}}$$

- Classificação binária por exemplo: **1** é spam e **0** not spam

Neurônios Artificiais

- O plano euclidiano \mathbb{R}^2 é separado em duas regiões, e o neurônio funciona como um discriminador linear de dimensão 2.




$$f(E) = \frac{1}{1 + e^{-E}}$$

$$b_1 w_1 + b_2 w_2 > E^* + \epsilon \rightarrow f(E) = f(b_1 w_1 + b_2 w_2) \cong 1000 \text{ pulso}$$

$$b_1 w_1 + b_2 w_2 < E^* - \epsilon \rightarrow f(E) = f(b_1 w_1 + b_2 w_2) \cong 0 \text{ pulsos/seg.}$$

Neurônios Artificiais



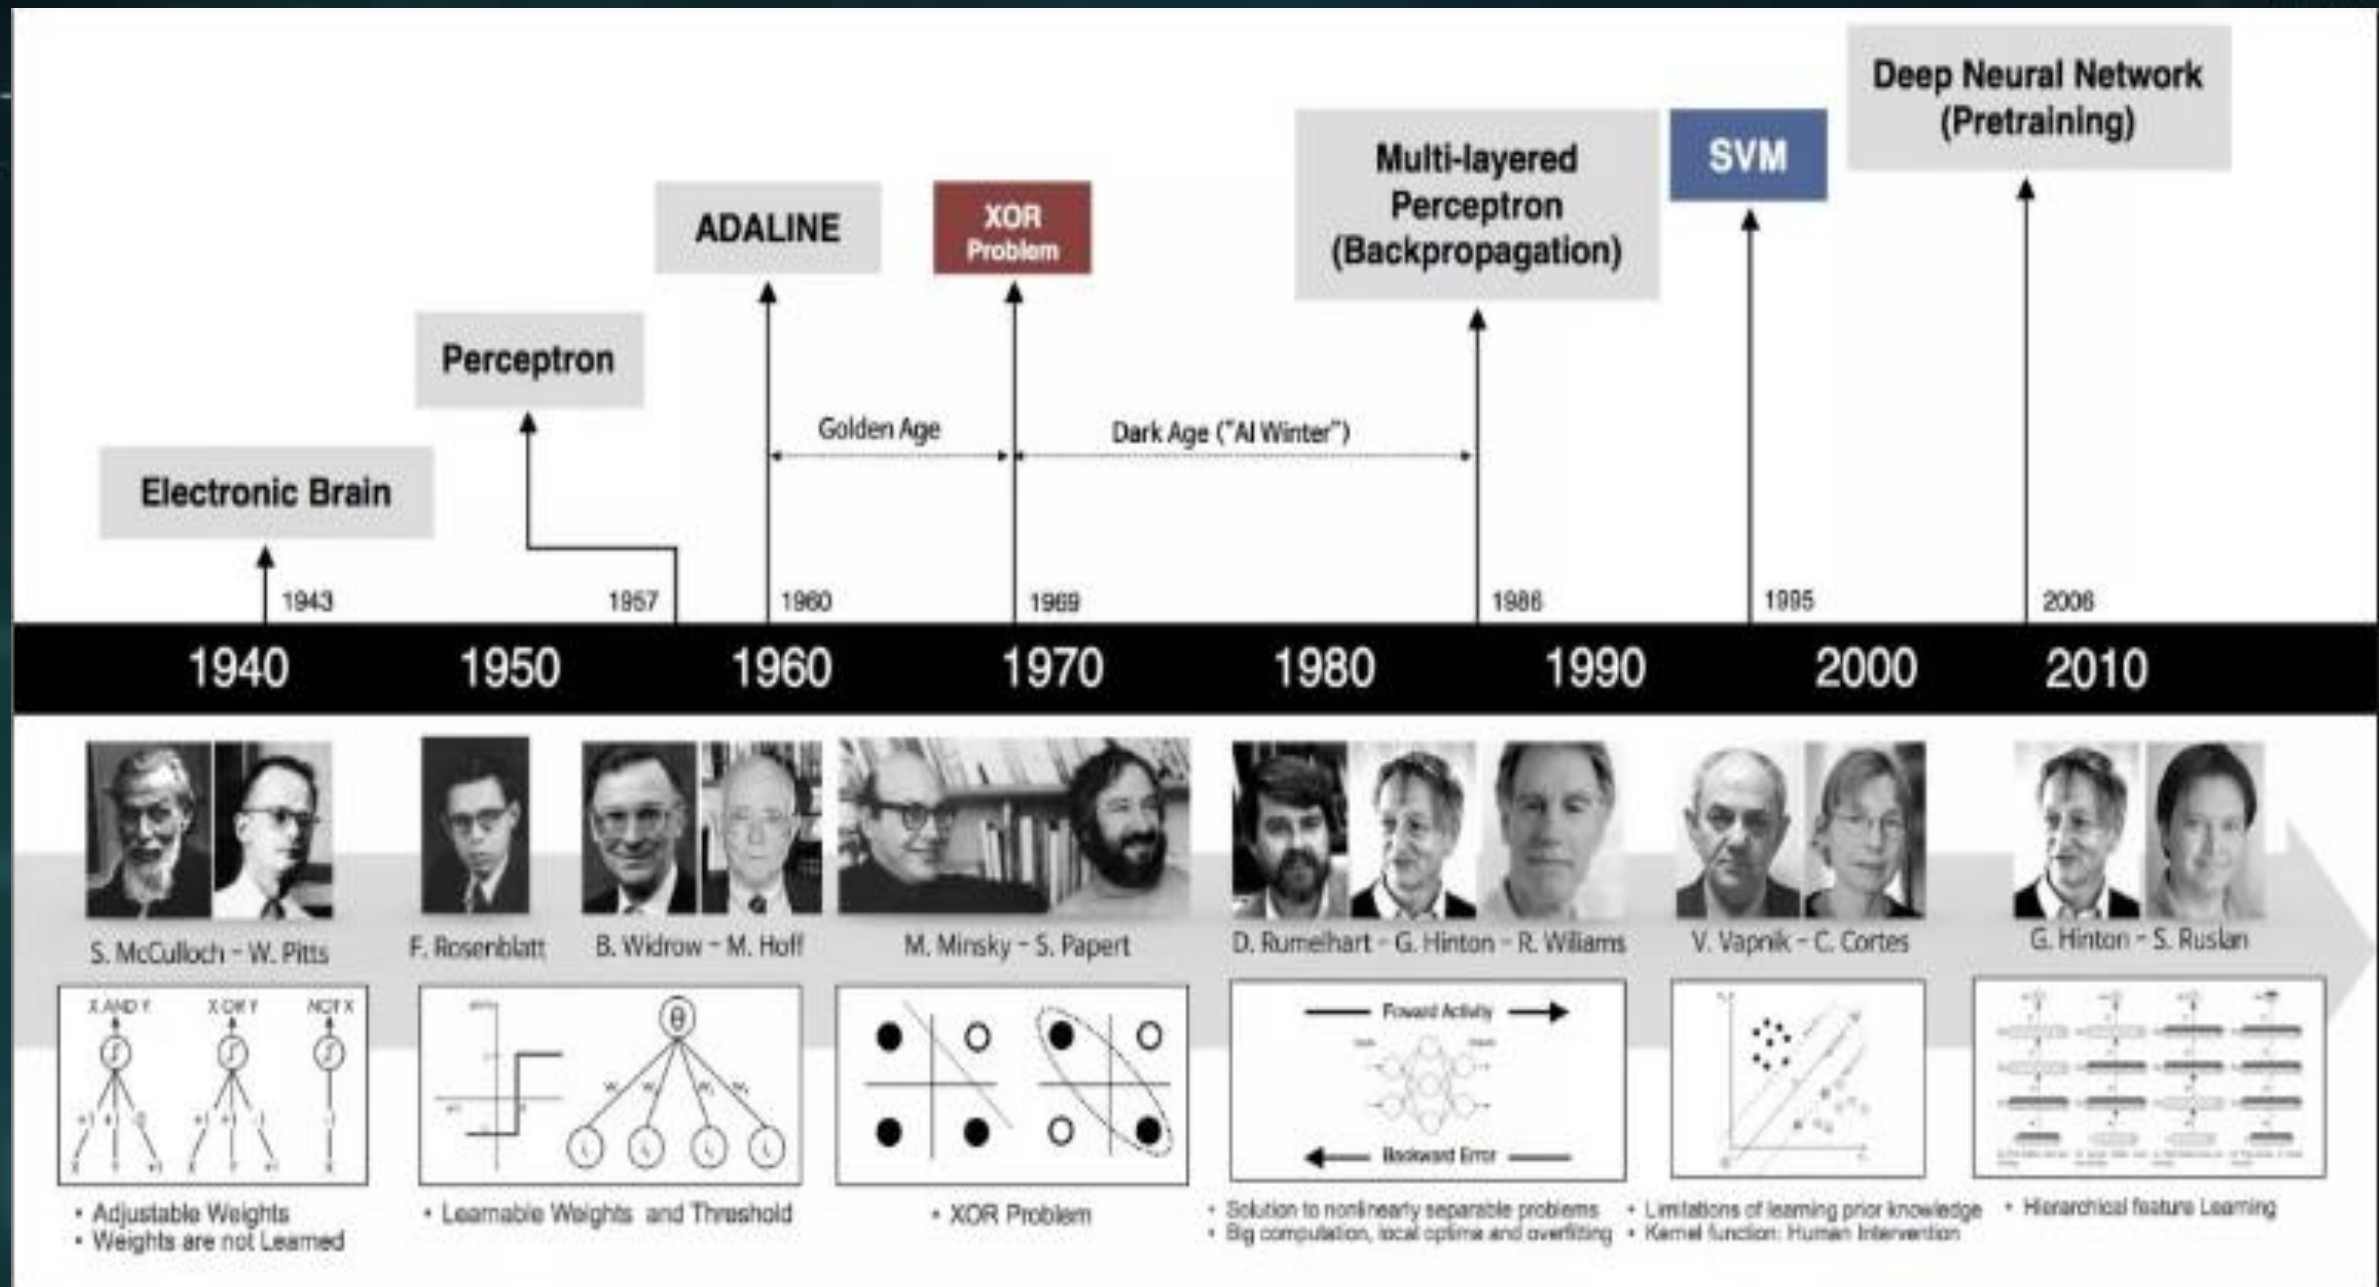
x_1 e x_2 são entradas binárias

A e B são padrões verificados (classificados)

w_i são os pesos sinápticos

$\sum x_i w_i$ é o hiperplano separador

y é a saída desejada (ou A ou B)



Tipos de aprendizado

- Existem até o momento 5 tipos de aprendizado:
 - Supervisionado
 - Não Supervisionado
 - Semi-supervisionado
 - Por Reforço
 - Transfer Learning

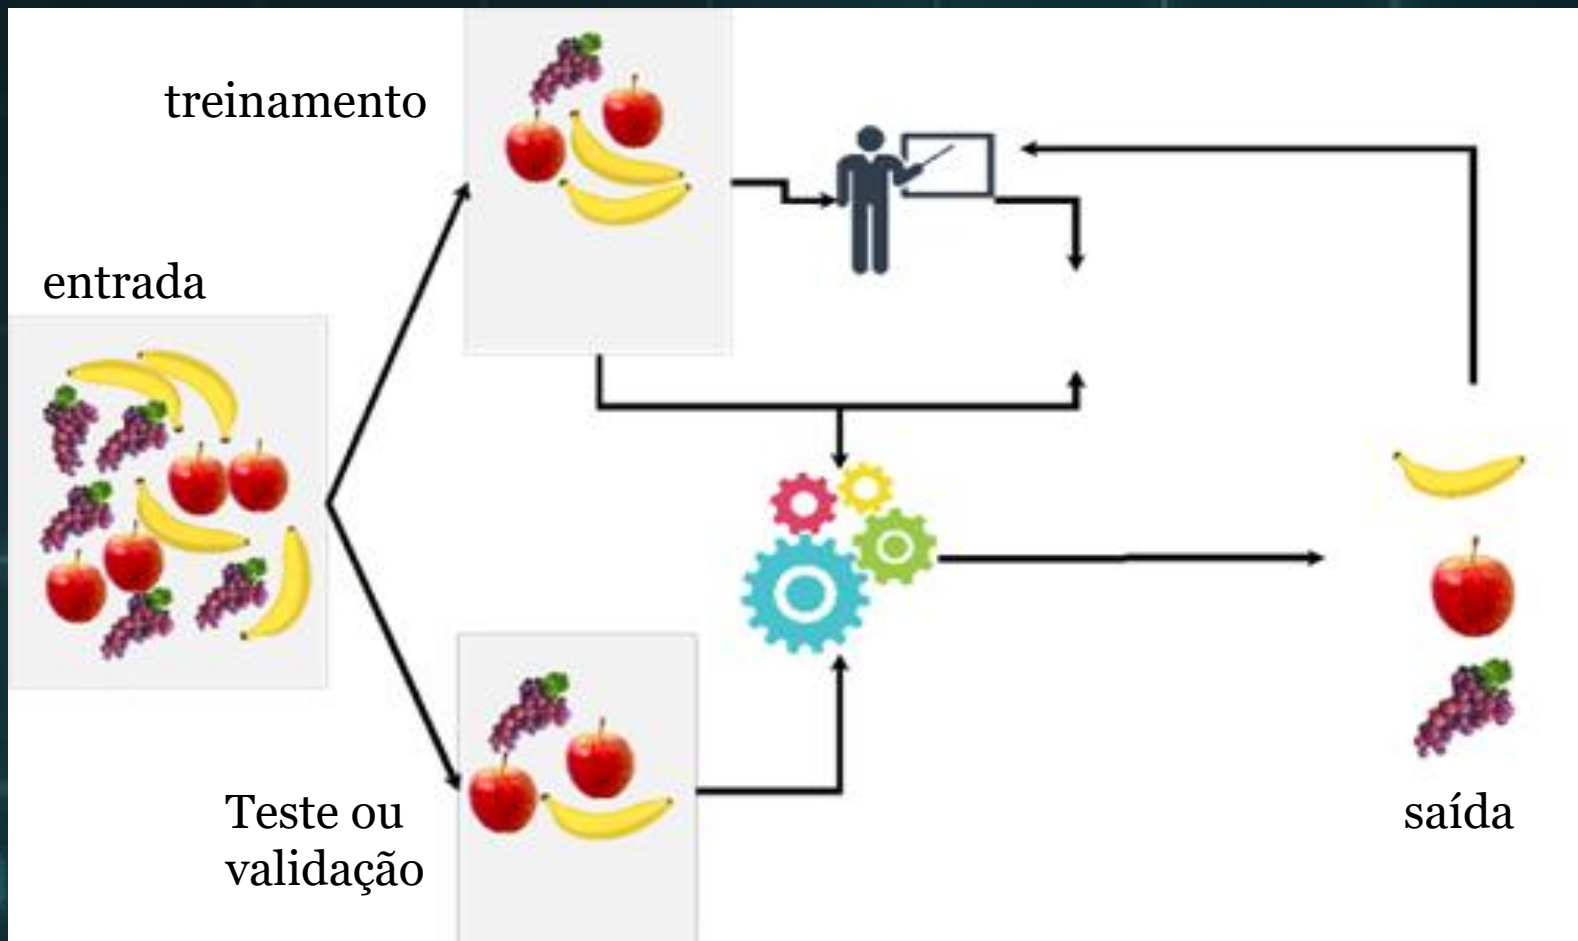
Tipos de aprendizado

- **Supervisionado**

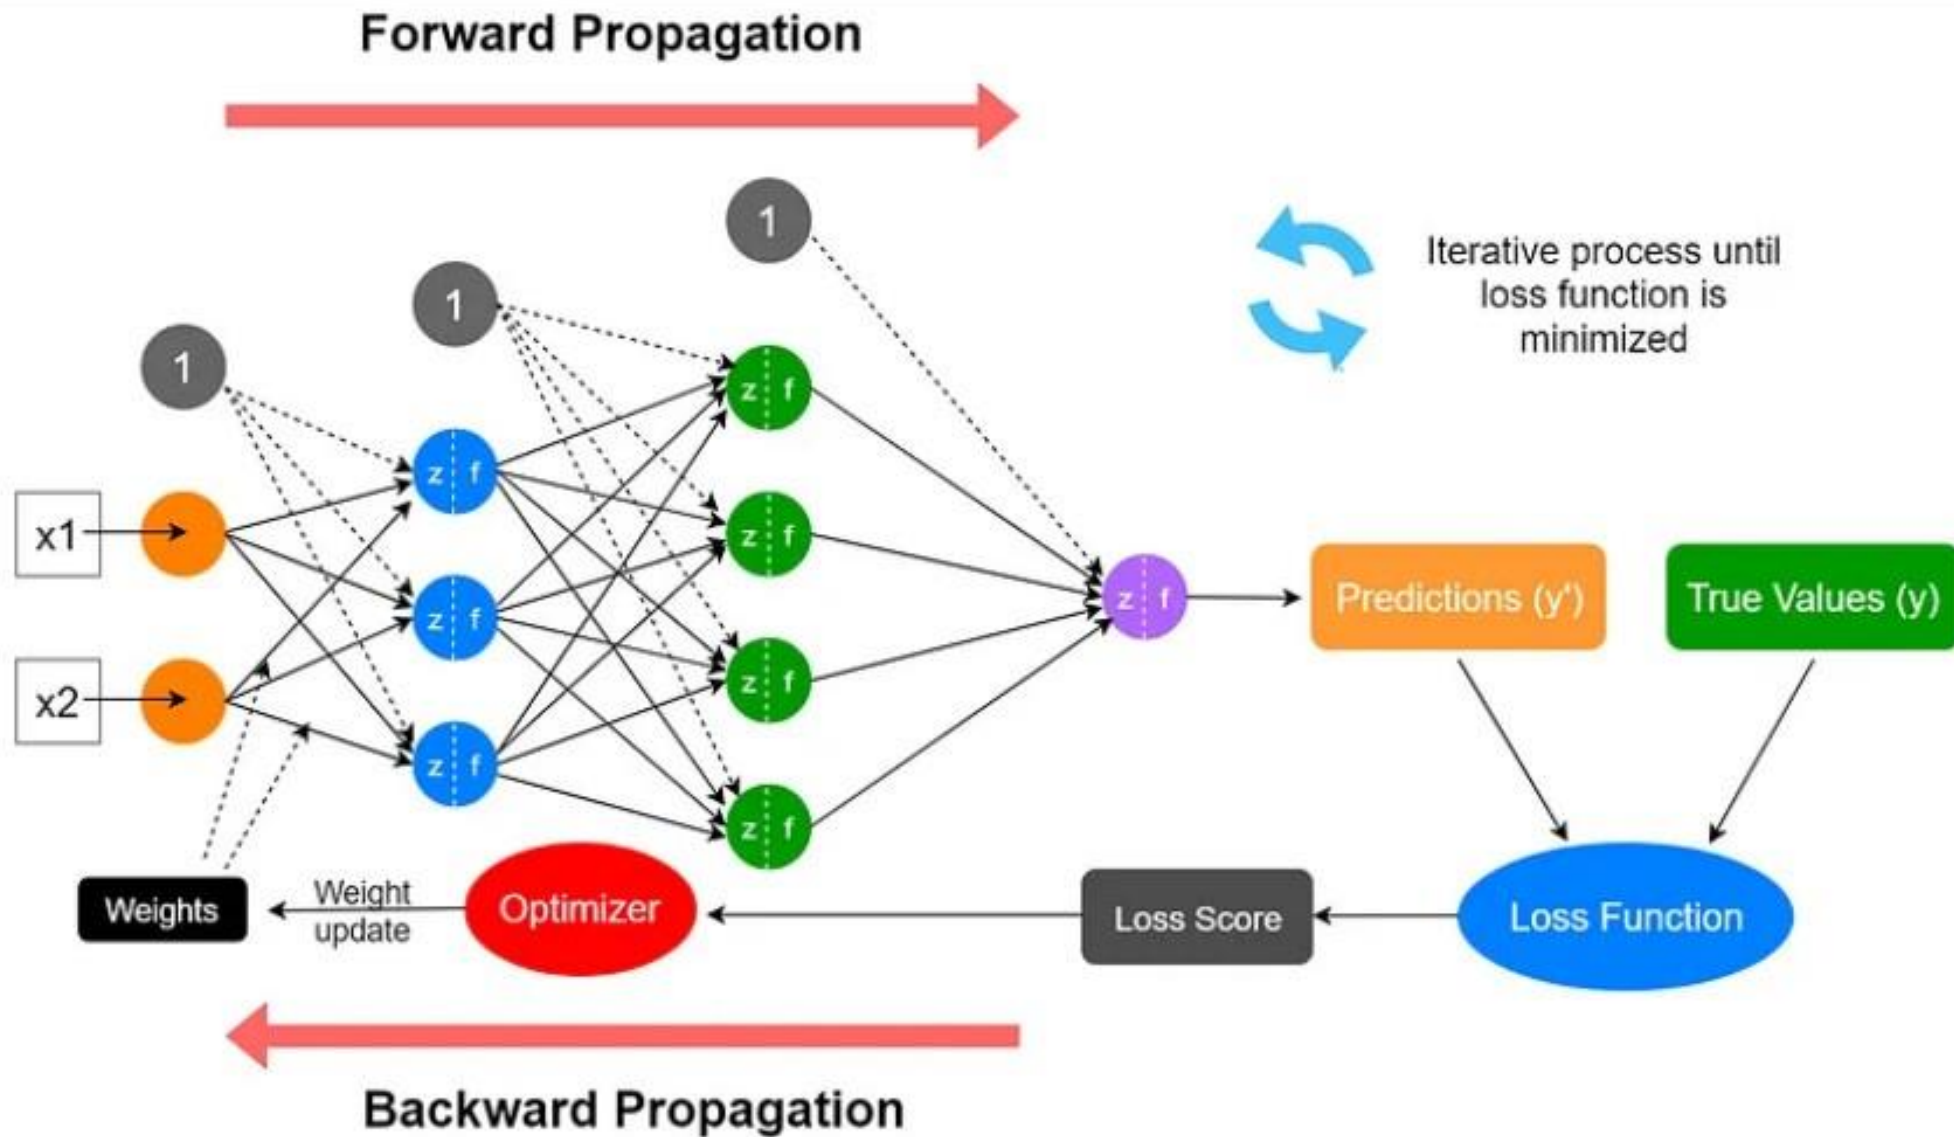
- é um paradigma que tem como objetivo adquirir informações de relacionamento entre entrada e saída de um sistema, baseado em um conjunto de amostras de treinamento.
- Busca-se prever uma variável dependente a partir de uma lista de variáveis independentes, chamadas de rótulos ou classes (labels).

Tipos de aprendizado

- Supervisionado



Propagação para frente e para trás



Propagação para frente e para trás

- Propagação para frente (Forward Propagation)
 - é o processo de passar os dados de entrada através da rede neural para obter a saída.
 - Cada neurônio recebe uma entrada, multiplica-a pelo peso correspondente, soma todas as entradas ponderadas (e adiciona um viés), e então passa essa soma através de uma função de ativação.
 - O resultado é então passado para a próxima camada, e assim por diante, até que a saída seja obtida.

Propagação para frente e para trás

- Viés:

- é um termo (entrada) adicional nas redes neurais que permite que o modelo se ajuste melhor aos dados.
 - semelhante ao termo de intercepção em uma equação linear.
- Em uma rede neural, cada neurônio tem um viés além dos seus pesos.

Propagação para frente e para trás

- Viés:

- O viés permite que o neurônio seja ativado ou não, mesmo quando todas as suas entradas são zero.
- Isso é importante porque permite que o neurônio capture padrões nos dados que não seriam possíveis apenas com os pesos.
 - Por exemplo, considere uma função linear simples $y = wx + b$, onde w é o peso, x é a entrada, b é o viés e y é a saída. Mesmo que x seja zero, a saída y ainda pode ser diferente de zero por causa do viés b .
- Na prática, o viés é implementado adicionando um nó extra em cada camada (exceto a camada de saída) que sempre tem o valor 1. Este nó é então conectado a cada neurônio na próxima camada com um peso, que é o valor do viés.

Propagação para frente e para trás

- Viés:

- Por exemplo, considere uma função linear simples $y = wx + b$, onde w é o peso, x é a entrada, b é o viés e y é a saída. Mesmo que x seja zero, a saída y ainda pode ser diferente de zero por causa do viés b .
- Na prática, o viés é implementado adicionando um nó extra em cada camada (exceto a camada de saída) que sempre tem o valor 1. Este nó é então conectado a cada neurônio na próxima camada com um peso, que é o valor do viés.

Propagação para frente e para trás

- Propagação para trás (Backpropagation)

- é o método usado para atualizar os pesos da rede neural com base no erro da saída.
- Primeiro, calcula-se o erro na saída.
- Em seguida, esse erro é propagado para trás através da rede, dando a cada neurônio uma “parcela” do erro para corrigir.
- Finalmente, os pesos são atualizados proporcionalmente ao quanto eles contribuíram para o erro.

