



# Universidade Federal Fluminense



## TÓPICOS ESP. SIST. INFORMAÇÃO



Prof.<sup>a</sup>Leila Weitzel

# 3. Treinamento redes neurais

# Extração de recursos ou features Extraction

- É um processo fundamental em aprendizado de máquina e redes neurais profundas.
- O que é Feature Extraction?
  - **Feature extraction** refere-se à transformação de dados brutos em um conjunto menor e mais significativo de características (ou atributos) que representam as informações essenciais do problema.
  - O objetivo é reduzir a dimensionalidade dos dados, mantendo as informações relevantes para a tarefa em questão.

# Extração de recursos ou features Extraction

- Como Funciona?

- Imagine um conjunto de dados com muitos atributos (por exemplo, pixels em uma imagem, palavras em um texto).
- A extração de características envolve selecionar ou criar um subconjunto desses atributos que melhor representam as características distintivas dos dados.
- Essas características podem ser usadas como entrada para algoritmos de aprendizado de máquina, como redes neurais profundas.



# Exatção de recursos ou features Extraction

- Exemplos de Feature Extraction:

- **Exatção de características de imagem:**

- Em reconhecimento de imagem, podemos usar técnicas como **PCA (Principal Component Analysis)** ou **CNN (Convolutional Neural Networks)** para extrair características relevantes das imagens.
    - Por exemplo, uma CNN pode aprender a detectar bordas, texturas e padrões específicos em imagens.

- **Exatção de características de texto:**

- Em processamento de linguagem natural, podemos usar **TF-IDF (Term Frequency-Inverse Document Frequency)** ou **word embeddings (como Word2Vec ou GloVe)** para representar palavras ou frases como vetores numéricos.
    - Esses vetores podem ser usados como entrada para redes neurais.

# Extração de recursos ou features Extraction

- Exemplos de Feature Extraction:

- **Extração de características de séries temporais:**

- Em séries temporais, podemos usar estatísticas resumidas (média, desvio padrão, etc.) ou transformações (como Fourier) para representar tendências e padrões.

- **Extração One-Hot Encoding (Codificação One-Hot):**

- Cada categoria é transformada em um vetor binário (0s e 1s).
    - Cada categoria se torna uma nova coluna, e o valor 1 indica a presença da categoria.
    - Exemplo:
      - Categoria “Cor”: [“Vermelho”, “Verde”, “Azul”]
      - Codificação One-Hot:
        - Vermelho: [1, 0, 0]
        - Verde: [0, 1, 0]
        - Azul: [0, 0, 1]

# Extração de recursos ou features Extraction

- Exemplos de Feature Extraction:

- **Label Encoding (Codificação de Rótulo):**

- Atribui um número inteiro único a cada categoria.
    - Pode ser usado quando há uma ordem natural nas categorias (por exemplo, baixo, médio, alto).
    - Exemplo:
      - Categoria “Tamanho”: [“Pequeno”, “Médio”, “Grande”]
      - Codificação de Rótulo:
        - Pequeno: 0
        - Médio: 1
        - Grande: 2

# Extração de recursos ou features Extraction

- Exemplos de Feature Extraction:

- **Target Encoding (Codificação do Alvo):**

- Usa a média da variável de destino (rótulo) para cada categoria.
    - Pode ser útil quando há uma relação entre a categoria e o rótulo.
    - Exemplo:

- Categoria “País”: [“Brasil”, “EUA”, “Japão”]

- Média de Vendas para cada país:

- Brasil: 1000
        - EUA: 2000
        - Japão: 1500
        - Codificação do Alvo:
        - Brasil: 1000
        - EUA: 2000
        - Japão: 1500



# Extração de recursos ou features Extraction

- Importância da Feature Extraction:
  - **Redução de Dimensionalidade:** A alta dimensionalidade pode levar a problemas de desempenho e overfitting. A extração de características ajuda a reduzir a quantidade de dados sem perder informações cruciais.
  - **Melhor Generalização:** Características bem escolhidas permitem que o modelo generalize melhor para novos dados.
  - **Eficiência Computacional:** Modelos treinados em conjuntos de dados menores (com menos características) são mais rápidos e eficientes.
  - **Interpretabilidade:** Características extraídas podem ser mais compreensíveis e interpretáveis do que os atributos originais.

# Extração de recursos ou features Extraction

- Exemplo: Extração de recursos usando One-Hot Vector (Vetor One-Hot) em Texto
- A extração de recursos usando vetores one-hot é uma técnica comum para representar palavras ou frases em formato numérico, especialmente em processamento de linguagem natural (NLP).
- O que é Vetor One-Hot?
  - Um vetor one-hot é uma representação binária de um elemento em um espaço de características.
  - Cada palavra ou categoria é mapeada para um vetor de zeros, exceto para uma posição que é marcada como 1.
  - Essa representação é útil para algoritmos de aprendizado de máquina, como redes neurais, que requerem entradas numéricas.

# Extração de recursos ou features Extraction

- Vamos criar um conjunto de dados com as três frases :
  - “Alice adora macarrão”
  - “Alice adora peixe”
  - “Alice e Bob são amigos”
- Primeiro, criaremos um vocabulário único contendo todas as palavras únicas nas frases.
- Construção do Vocabulário:
  - O vocabulário é: [“Alice”, “adora”, “macarrão”, “peixe”, “e”, “Bob”, “são”, “amigos”]
- Agora, vamos criar vetores one-hot para cada frase

# Extração de recursos ou features Extraction

- **Base de Dados One-Hot:**

- Agora, podemos representar cada frase como uma combinação desses vetores one-hot.
- Por exemplo, a primeira frase “Alice adora macarrão” seria representada como:

**[1, 1, 1, 0, 0, 0, 0, 0]** (Alice + adora + macarrão)

- As outras frases também seriam representadas de maneira semelhante.
- O vetor one-hot permite que o modelo aprenda a associar palavras específicas a contextos ou classes.
- É uma representação simples e eficaz para tarefas de NLP, como classificação de texto, análise de sentimento e geração de texto.

Palavra	Vetor One-Hot
“Alice”	[1, 0, 0, 0, 0, 0, 0, 0]
“adora”	[0, 1, 0, 0, 0, 0, 0, 0]
“macarrão”	[0, 0, 1, 0, 0, 0, 0, 0]
“peixe”	[0, 0, 0, 1, 0, 0, 0, 0]
“e”	[0, 0, 0, 0, 1, 0, 0, 0]
“Bob”	[0, 0, 0, 0, 0, 1, 0, 0]
“são”	[0, 0, 0, 0, 0, 0, 1, 0]
“amigos”	[0, 0, 0, 0, 0, 0, 0, 1]

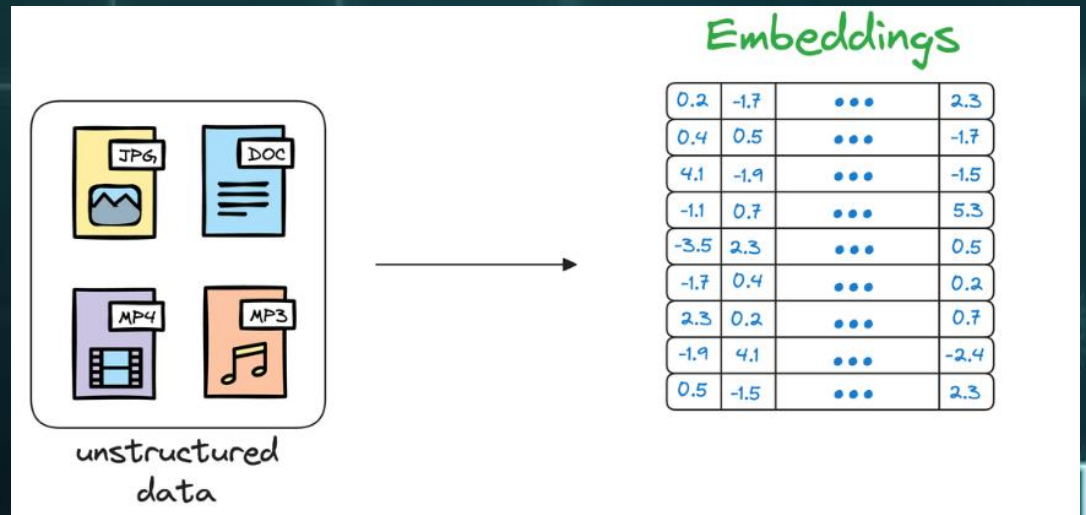


# Banco de dados vetoriais

- Antes de falarmos sobre word embedding que uma outra técnica de extração de recursos, vamos falar sobre banco de dados vetoriais.
- os bancos de dados vetoriais NÃO são novos.
- Na verdade, eles já existem há muito tempo.
- Você tem interagido indiretamente com eles diariamente, mesmo antes de se tornarem amplamente populares ultimamente.
- Isso inclui aplicativos como sistemas de recomendação e mecanismos de pesquisa, por exemplo.

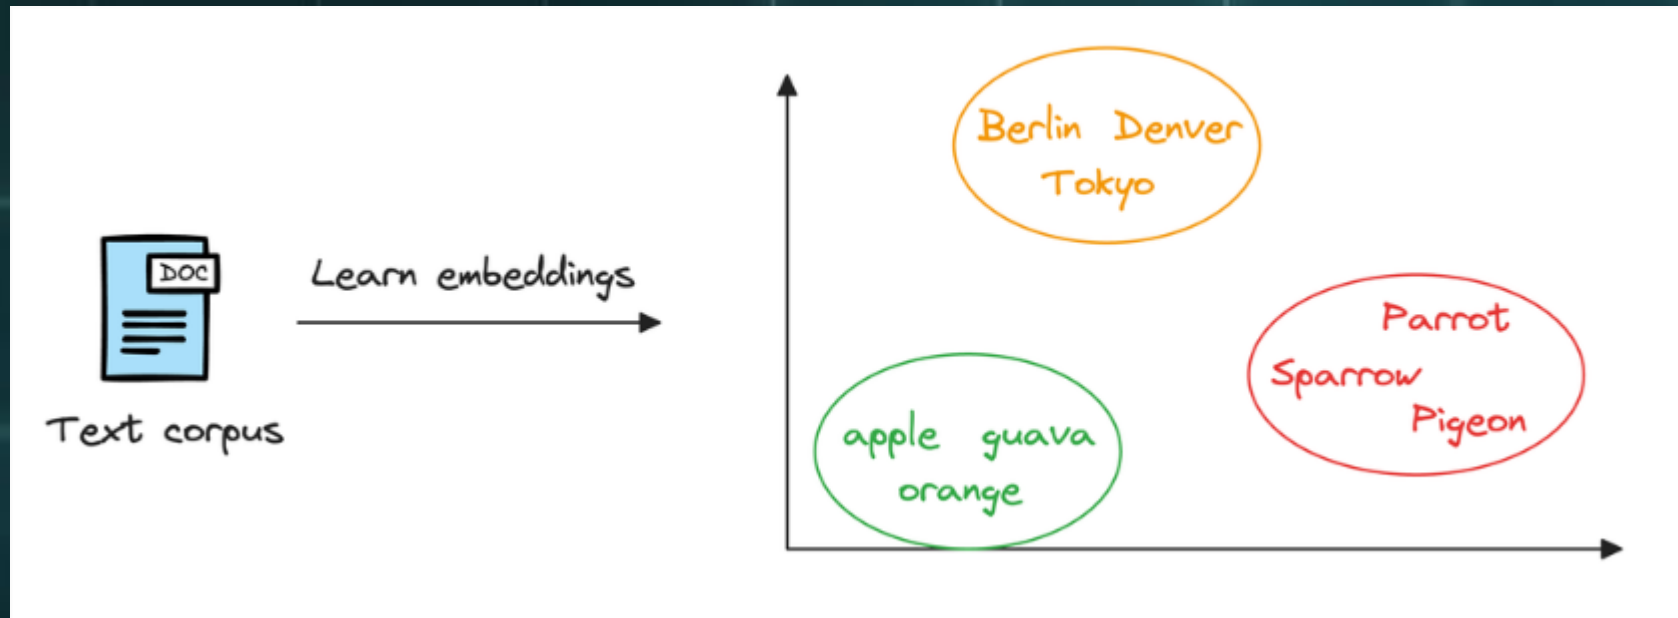
# Banco de dados vetoriais

- um banco de dados vetorial armazena **dados não estruturados** (texto, imagens, áudio, vídeo, etc.) na forma de **incorporações vetoriais**.
- Cada ponto de dados, seja uma palavra, um documento, uma imagem ou qualquer outra entidade, é transformado em um vetor numérico por meio de técnicas de ML (que veremos a seguir).
- Esse vetor numérico é chamado de **incorporação**, e o modelo é treinado de forma que esses vetores capturem os recursos e características essenciais dos dados subjacentes.




# Banco de dados vetoriais

- Suponha que nossa base de dados (text\_corpus) tem nomes de frutas, pássaros e cidades. Queremos separar estes conceitos
- Isso mostra que os embeddings podem aprender as características semânticas das entidades que representam (desde que sejam treinados adequadamente).



# Banco de dados vetoriais

- Uma vez armazenados em um banco de dados vetorial, podemos recuperar objetos originais semelhantes à consulta que desejamos executar em nossos dados não estruturados.
- Em outras palavras, a codificação de **dados não estruturados** nos permite executar muitas operações tais como pesquisa de similaridade, agrupamento e classificação, o que de outra forma seria difícil com bancos de dados tradicionais.



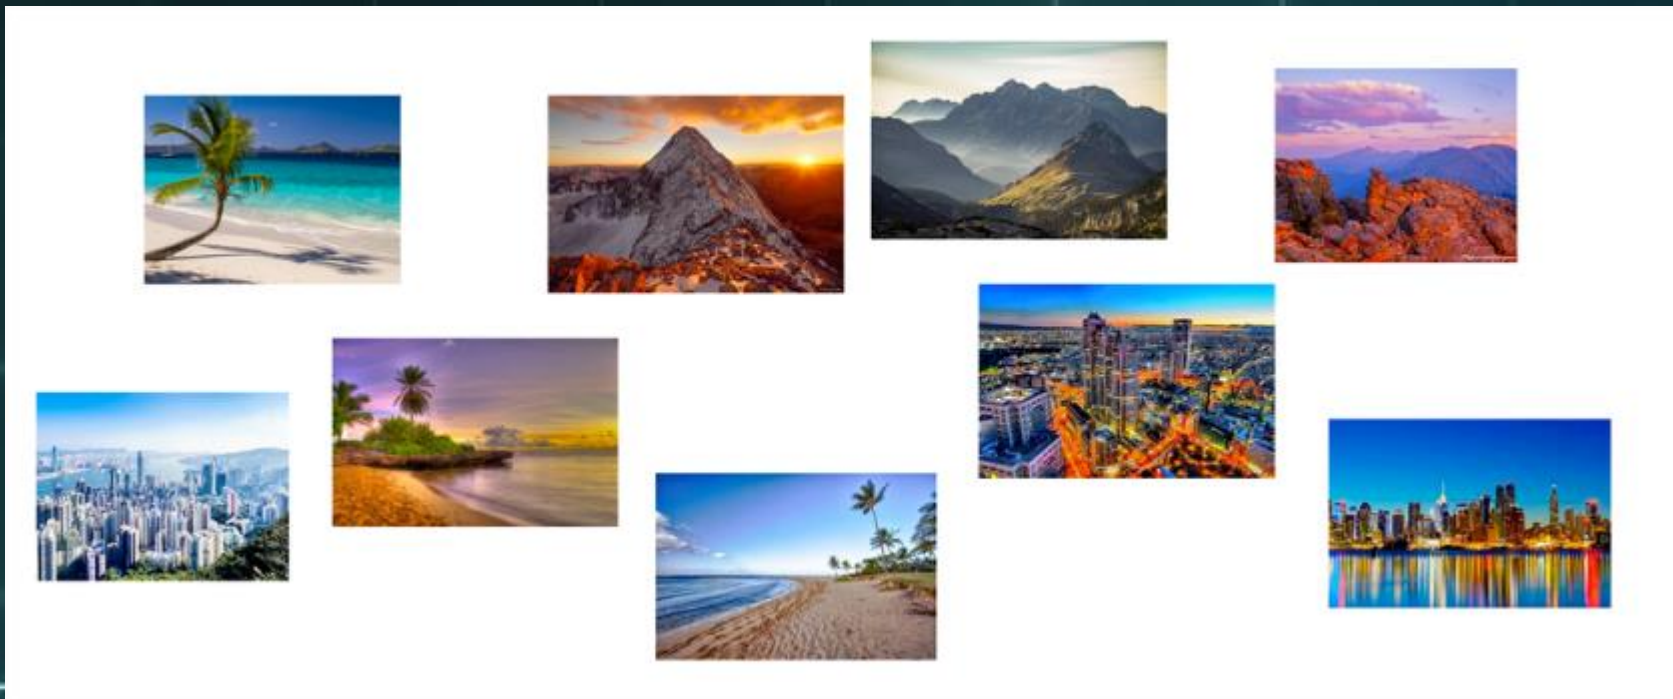


## Banco de dados vetoriais

- Para exemplificar, quando um site de comércio eletrônico fornece recomendações para itens semelhantes ou procura um produto com base na consulta de entrada, estamos ( **na maioria dos casos** ) interagindo com bancos de dados vetoriais nos bastidores.
- Chamados de sistemas de recomendação; Netflix, Amazon etc..

# Banco de dados vetoriais

- Vamos imaginar que temos uma coleção de fotografias de diversas férias que tiramos ao longo dos anos. Cada foto captura cenas diferentes, como praias, montanhas, cidades e florestas.



# Banco de dados vetoriais

- Agora, queremos organizar essas fotos de uma forma que facilite a localização rápida de fotos semelhantes.
- Tradicionalmente, podemos organizá-los pela data em que foram tiradas ou pelo local onde foram filmadas.



# Banco de dados vetoriais

- em vez de depender apenas de datas ou locais, poderíamos representar cada foto como um conjunto de vetores numéricos que capturam a essência da imagem.
- Embora o Google Fotos não divulgue explicitamente os detalhes técnicos exatos de seus sistemas de back-end, especulo que ele usa um banco de dados vetorial para facilitar seus recursos de pesquisa e organização de imagens, que você já deve ter usado muitas vezes.



## Banco de dados vetoriais

- Cada foto é agora representada como um ponto num espaço multidimensional, onde as dimensões correspondem a diferentes características visuais e elementos da imagem.
- quando queremos encontrar fotos semelhantes, digamos, com base em nossa consulta de texto de entrada, codificamos a consulta de texto em um vetor e a comparamos com vetores de imagem.

# Banco de dados vetoriais

- Nesse caso, podemos encontrar rapidamente essas fotos consultando o banco de dados vetorial em busca de imagens próximas ao vetor que representa a consulta de entrada.




## Banco de dados vetoriais

- Quando um usuário consulta imagens de montanhas, ele recebe uma lista de vetores que representam imagens semelhantes, mas sem as imagens reais.



# Banco de dados vetoriais

- considere dados não estruturados totalmente em texto, digamos, milhares de artigos de notícias, e desejamos procurar uma resposta a partir desses dados.






# Banco de dados vetoriais

- Os métodos de pesquisa tradicionais dependem da pesquisa exata por palavra-chave, que é inteiramente uma abordagem de força bruta e não considera a complexidade inerente dos dados de texto.
- Por exemplo, uma pergunta simples como “Como está o tempo hoje?” pode ser formulado de várias maneiras, como "Como está o tempo hoje?", "Está ensolarado lá fora?" ou "Quais são as condições climáticas atuais?".
- Esta diversidade linguística torna inadequados os métodos tradicionais de pesquisa baseados em palavras-chave.

# Banco de dados vetoriais

- Em vez de depender apenas de palavras-chave e seguir uma pesquisa de força bruta, podemos primeiro representar dados de texto em um espaço vetorial de alta dimensão e armazená-los em um banco de dados vetorial.



# Banco de dados vetoriais

- **Como gerar embeddings?**
- Neste ponto, se você está se perguntando como podemos transformar palavras (strings), imagens etc em vetores (uma lista de números)
- Vamos ao exemplo de gerar embeddings a partir de texto.

# Extração de recursos ou features Extraction

- Word Embeddings
- Na área da PLN, os métodos de representação de texto supervisionados, tais como *Word Embeddings* incorporação de palavras (WE), veio a substituir os métodos de representação categórica de texto que utilizam a matriz de co-ocorrência de palavras Também chamado de **incorporação de palavras**.




# Extração de recursos ou features Extraction


- O objetivo dos embeddings é capturar relações semânticas e sintáticas entre palavras. Isso ajuda as máquinas a compreender e raciocinar sobre a linguagem de maneira mais eficaz.
- Na era pré-Transformers, isso era feito principalmente usando embeddings **estáticos pré-treinados**.
  - As técnicas mais atuais usam os Transformers. Um modelo Transformer é uma rede neural que aprende o contexto e o significado ao monitorar relações em dados sequenciais, como as palavras em uma frase. Este assunto não está previsto na disciplina

# Extração de recursos ou features Extraction


- Palavras que tem a mesma semântica estão no mesmo espaço vetorial



Male-Female




Verb Tense



Country-Capital

# Extração de recursos ou features Extraction

- Palavras que possuem significados semelhantes ou que ocorrem frequentemente juntas em contextos semelhantes terão uma representação vetorial semelhante, com base em quão “próximas” ou “distantes” essas palavras estão em seus significados.



# Extração de recursos ou features Extraction


- t-SNE (t-Distributed Stochastic Neighbor Embedding)

- É uma técnica de redução de dimensionalidade não linear.
  - O objetivo é representar dados de alta dimensão em um espaço menor, preservando as relações entre os pontos.
- Ele usa uma abordagem baseada em vizinhos próximos para preservar a estrutura local dos dados.
- Usado para visualizar representações latentes aprendidas por redes neurais.
- Pode ser aplicado a vetores de características extraídos de redes neurais convolucionais (CNNs) para visualizar agrupamentos de imagens com base em similaridade.



# Extração de recursos ou features Extraction

- Word Embeddings



# Codificação dos rótulos

- Existem várias razões para se codificar os rótulos em formato numérico
  - Compatibilidade com Algoritmos:
    - A maioria dos algoritmos de aprendizado de máquina, incluindo redes neurais, trabalha com valores numéricos.
    - Ao codificar os rótulos numericamente, tornamos os dados compatíveis com esses algoritmos.
    - Exemplo: Se temos três classes (gato, cachorro, pássaro), podemos atribuir os valores 0, 1 e 2 a essas classes.

# Codificação dos rótulos

- Existem várias razões para se codificar os rótulos em formato numérico
  - Cálculos Matemáticos:
    - Durante o treinamento da rede neural, muitos cálculos matemáticos são realizados.
    - É mais eficiente trabalhar com números do que com rótulos de texto.
    - Exemplo: Ao calcular gradientes para atualizar os pesos da rede, é mais fácil se os rótulos forem números.

# Codificação dos rótulos

- Existem várias razões para se codificar os rótulos em formato numérico

## – Funções de Ativação:

- As funções de ativação nas camadas da rede neural também esperam entradas numéricas.
- Exemplo: A função ReLU (Rectified Linear Unit) só funciona com valores numéricos.



# Codificação dos rótulos

- Existem várias razões para se codificar os rótulos em formato numérico

## – Comparação e Medição de Desempenho:

- Para avaliar o desempenho do modelo, comparamos as previsões com os rótulos reais.
- Isso só é possível se ambos forem representados numericamente.
- Exemplo: Calcular a acurácia comparando as previsões com os rótulos verdadeiros

# Codificação de rótulos

- Existem diferentes tipos de codificação que podem ser aplicados a uma base de dados antes de usá-la para treinar uma rede neural.

## 1. Codificação Numérica (One-Hot Encoding)

- É o método mais comum para codificar variáveis categóricas.
- Cada categoria é representada por um vetor binário, onde apenas um elemento é 1 (indicando a classe) e os outros são 0.
  - Exemplo: Se tivermos três classes (gato, cachorro, pássaro), o vetor one-hot para "cachorro" seria  $[0, 1, 0]$ .

# Codificação de rótulos

## 2. Codificação Ordinal:

- Usado quando as categorias têm uma ordem natural.
- Atribui valores numéricos às categorias com base em sua posição na ordem.
  - Exemplo: Classificação de níveis de educação (fundamental, médio, superior).

# Codificação de rótulos

## 3. Codificação de Rótulos (Label Encoding):

- Cada categoria é mapeada para um valor numérico único.
- Útil para variáveis categóricas com muitas categorias.
  - Exemplo: Atribuir números sequenciais a nomes de países.



# Codificação de rótulos

## 4. Codificação de Texto (Word Embeddings):

- Usado para representar palavras ou frases em vetores numéricos.
- Modelos pré-treinados (como Word2Vec, GloVe) convertem palavras em vetores densos.
  - Exemplo: Representar palavras em análise de sentimentos.

# Codificação de rótulos

## 5. Codificação Temporal:

- Usado para sequências temporais.
- Pode incluir timestamps, durações, sazonalidades, etc.
  - Exemplo: Previsão de vendas ao longo do tempo.

# Codificação de rótulos

## 6. Codificação de Imagens (Convolutional Neural Networks - CNN):

- Redes neurais convolucionais extraem características de imagens.
- Pixels de imagens são codificados em tensores multidimensionais.
  - Exemplo: Classificação de objetos em imagens.









**THIS IS THE WAY**



See You  
Next time